

Educación Continua dcc

fcfm FACULTAD DE CIENCIAS FÍSICAS Y MATEMÁTICAS UNIVERSIDAD DE CHILE

dcc CIENCIAS DE LA COMPUTACIÓN UNIVERSIDAD DE CHILE

Taller:
El mundo del Big Data a través del cine

Aidan Hogan, Profesor del DCC

Educación Continua dcc

Diploma en Ciencia e Ingeniería de Datos - U. de Chile

Lidera la toma de decisiones basadas en datos en la era de la IA

DETALLES DEL PROGRAMA

Inicio: abril 2027
Término: agosto 2027

Modalidad: Online con clases en vivo

Horarios: Lun, Mar y Jue de 18:30 a 21:30 h. Un sábado al mes de 9:00 a 12:00.

MALLA CURRICULAR

- ➔ Programación Estadística
- ➔ Visualización de Datos
- ➔ Recuperación de Información
- ➔ Aprendizaje de Máquinas y Deep Learning
- ➔ Minería de Datos
- ➔ Big Data
- ➔ Taller de Proyecto

Más información: dcc.uchile.cl/datos

¿Qué van a ver esta noche?











Podemos usar Big Data + IMDb para contestar



Los datos de IMDb quedan disponibles

IMDb Data Files Available for Download

Documentation for these data files can be found on IMDb Non-Commercial Datasets.

The data files available on this page are provided for non-commercial use only. As of March 18, 2024 the datasets on this page are backed by a new data source. There has been no change in location or schema, but if you encounter issues with the datasets following the March 18th update, please contact imdb-data-interest@imdb.com.

name.basics.tsv.gz

title.akas.tsv.gz

title.basics.tsv.gz

title.crew.tsv.gz

title.episode.tsv.gz

title.principals.tsv.gz

title.ratings.tsv.gz

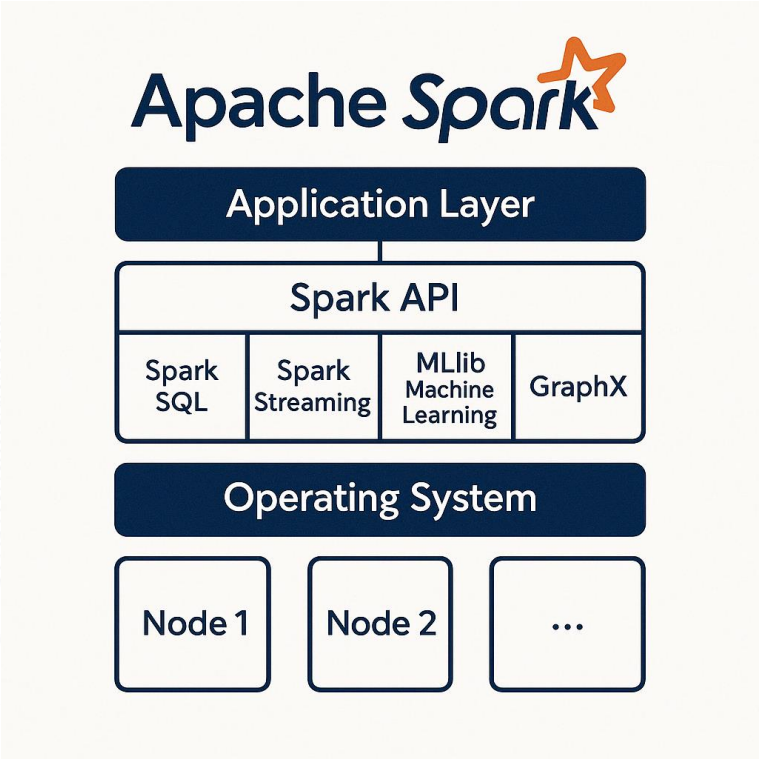
Pero son grandes

Archivo	Comprimido	Descomprimido	Filas	Columnas
name.basics.tsv.gz	304MB	973MB	12.881.969	6
title.akas.tsv.gz	506MB	3.033MB	59.861.136	8
title.basics.tsv.gz	224MB	1.118MB	12.881.968	9
title.crew.tsv.gz	81MB	424MB	12.881.680	3
title.episode.tsv.gz	54MB	262MB	9.963.519	4
title.principals.tsv.gz	769MB	4.400MB	102.408.464	6
title.ratings.tsv.gz	8MB	30MB	1.723.236	6

Para la parte de Big Data usaremos Apache Spark



Para la parte de Big Data usaremos Apache Spark



Spark SQL

PySpark

Educación Continua dcc

Taller: El mundo del Big Data a través del cine

El mundo del Big Data a través del cine

En este taller usaremos **Apache Spark (PySpark)** para explorar los datos públicos de IMDb desde nuestro propio computador. Veremos una demostración durante el taller, pero opcionalmente, al seguir estas instrucciones (idealmente antes del taller, o en caso contrario cuando puedas), también puedes correr todo localmente desde tu computador.

Las instrucciones sirven para **Windows, macOS y Linux**.

Estimo que se necesitará en el orden de **20 GB de espacio libre en disco** (idealmente más).



https://github.com/aidhog/big-data-cine

¿Qué significa “Big Data”?



¿Qué significa “Big Data”?





¿Cómo escalar más? (1)



¿Cómo escalar más? (2)

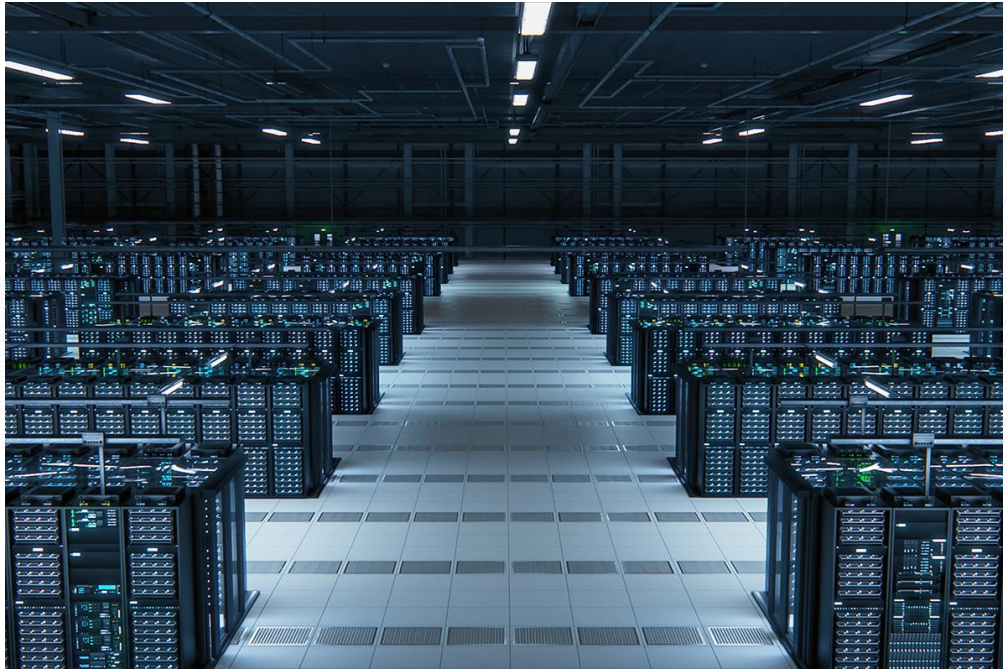


¿Cómo escalar más? (3)





¿Cómo escalar más? (3)



Educación Continua dcc

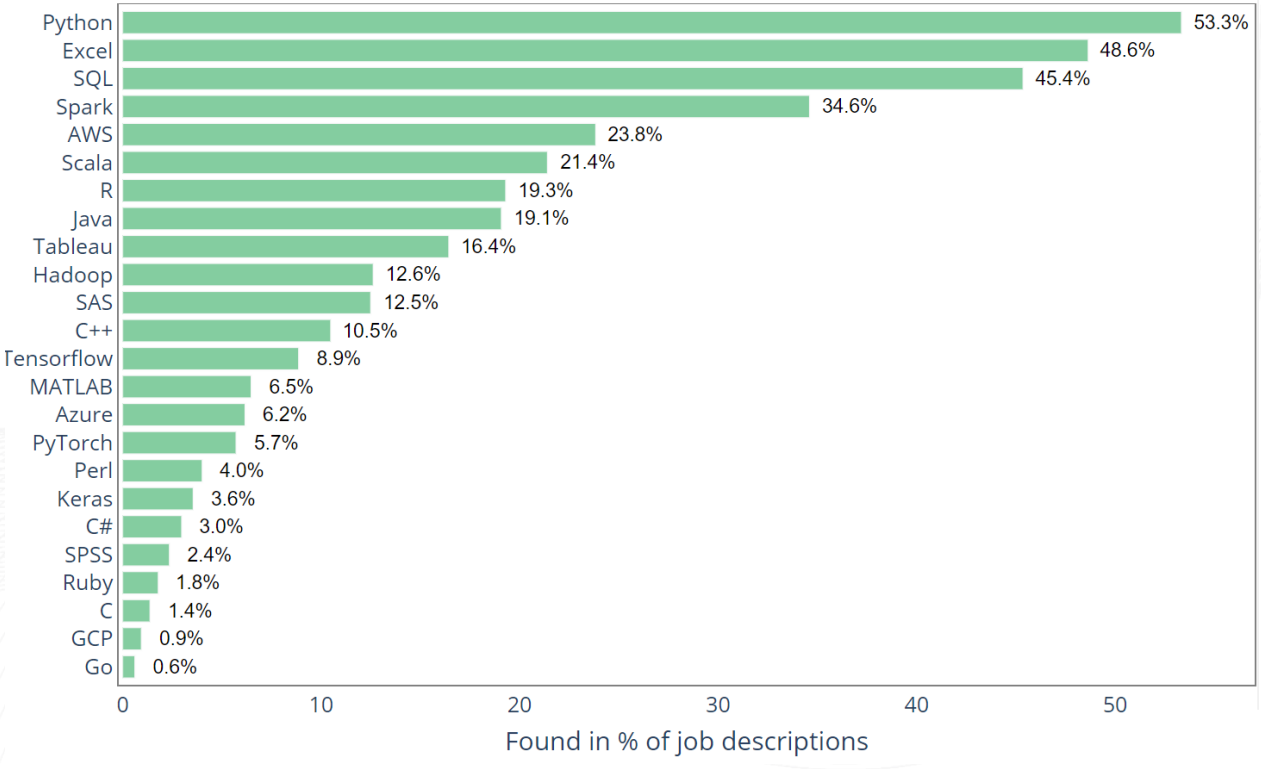
Big Data en el Diploma en Ciencia e Ingeniería de Datos

- Introducción a Big Data
- Sistemas de archivos distribuidos
- Frameworks distribuidos para procesar datos
- Recuperación de información
- Gestión de datos distribuida (NoSQL)



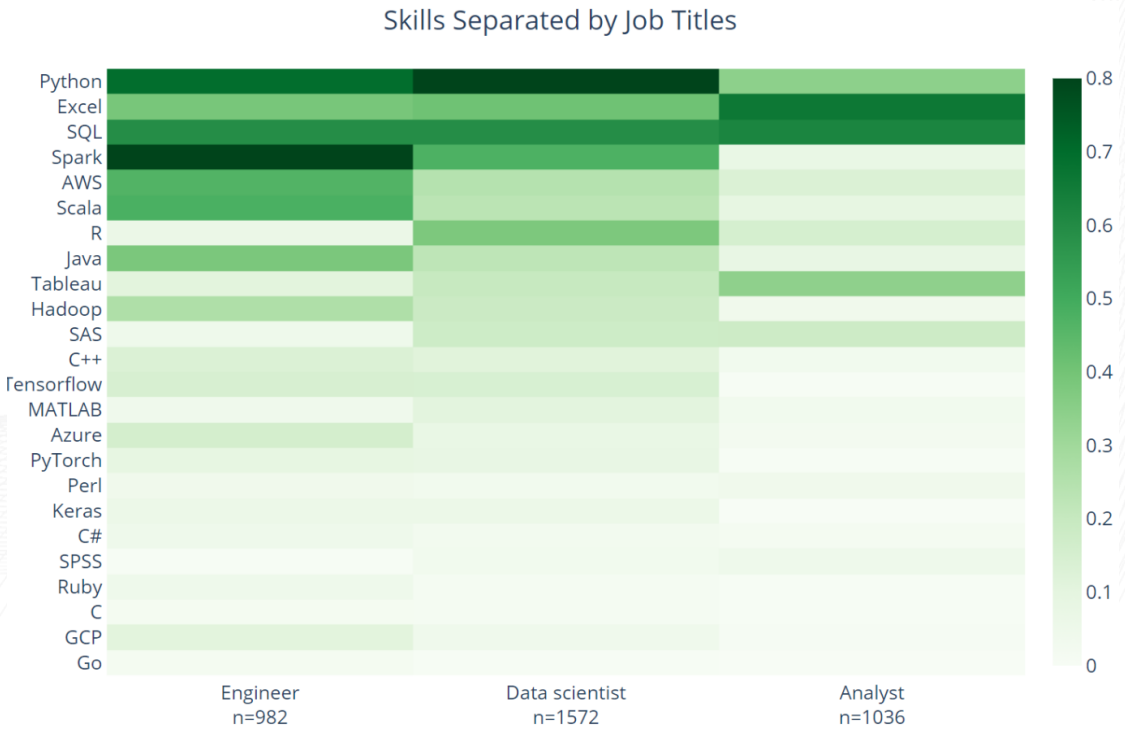


Ofertas de Trabajo para “Data Scientist”



https://medium.com/@chihhsulin/5-500-data-scientist-jobs-report-2020-adefe1d364d3

Ofertas de Trabajo para “Data Scientist”



https://medium.com/@chihhsulin/5-500-data-scientist-jobs-report-2020-adefe1d364d3

Educación Continua dcc

Diploma en Ciencia e Ingeniería de Datos - U. de Chile

Lidera la toma de decisiones basadas en datos en la era de la IA

DETALLES DEL PROGRAMA

Inicio: abril 2027
Término: agosto 2027

Modalidad: Online con clases en vivo

Horarios: Lun, Mar y Jue de 18:30 a 21:30 h. Un sábado al mes de 9:00 a 12:00.

MALLA CURRICULAR

- ➔ Programación Estadística
- ➔ Visualización de Datos
- ➔ Recuperación de Información
- ➔ Aprendizaje de Máquinas y Deep Learning
- ➔ Minería de Datos
- ➔ Big Data
- ➔ Taller de Proyecto

Más información: dcc.uchile.cl/datos



Síguenos en nuestras redes sociales

/ educacioncontinuadcc